

Data Visualization Phase 1
Nama: Deken Febriano Putra
NIM: 2802410125

1. Context & Visual Analytics Perspective.

- a. Explain the background of the case and the **visualization perspective** used to explore the data.

Dataset yang group saya pilih kali ini adalah Employee Dataset, berikut adalah link kaggle nya: <https://www.kaggle.com/datasets/tawfikelmetwally/employee-dataset>. Dalam dataset ini berisikan informasi tentang data karyawan, seperti education, joining year, city, payment tier, age, gender, ever benched, experience in current domain dan leave or not. Beberapa penjelasan dari nama kolom yang terdengar tidak familiar:

- Ever Benched: Apakah karyawan pernah tidak punya pekerjaan sementara di perusahaan.
- Experience in Current Domain: Jumlah Tahun pengalaman karyawan di bidang yang sekarang dikerjakan.
- Leave or Not(Target Column): Status karyawan apakah masih di perusahaan atau sudah keluar.

Dari berbagai isi kolom dataset kelompok saya, tentunya ada banyak sekali kemungkinan yang bisa di analisis, seperti age vs payment tier, mencari persentase dari terkecil sampai terbesar untuk joining year di perusahaan, apakah ever benched related dengan experience in current domain, dan masih banyak lagi. Jadi, analisis ini tidak hanya berfokus pada satu variabel saja tapi juga digunakan untuk melihat hubungan antar variabel.

Dalam proses eksplorasi dataset ini, analisis awal kelompok saya dimulai dari melihat gambaran umum melalui distribusi data, jadi kita bisa mengetahui karakteristik variabel di dalam employee dataset. Dengan seperti ini, kami bisa melihat visualisasi data secara terpisah dan juga bisa memahami setiap variabel dan mencari tahu variabel mana yang berhubungan satu sama lain. Melalui visualisasi pun, kita bisa mencari pola-pola dari graph sehingga bisa memberikan gambaran yang lebih jelas dan menyeluruh terhadap isi dataset.

- b. Describe the **role of data visualization** at this stage of the Group Project (before dashboards or storytelling).

Pada tahap awal sebelum masuk ke pembuatan dashboard atau storytelling, visualisasi data digunakan untuk memahami isi dataset secara menyeluruh. Dengan mengubah data menjadi grafik, kita dapat lebih mudah melihat pola serta memahami informasi yang terdapat dalam dataset dengan lebih cepat. Selain itu, visualisasi juga membantu dalam melihat hubungan antar variabel, misalnya dengan membandingkan beberapa kolom untuk mengetahui apakah terdapat keterkaitan tertentu. Dengan adanya visualisasi, proses analisis menjadi lebih mudah karena informasi yang sebelumnya sulit terlihat dalam data mentah menjadi lebih jelas dalam bentuk visual.

- c. Explain how visualization helps reveal structure, variation, or comparison in the data that may not be visible from raw tables.

Visualisasi data membantu kita melihat isi data dengan lebih jelas dibandingkan hanya membaca tabel biasa. Kalau masih dalam bentuk tabel, kita harus melihat angka satu per satu, jadi agak sulit untuk

langsung menemukan pola atau hubungan tertentu. Dengan visualisasi, data diubah menjadi grafik sehingga informasi bisa lebih cepat dipahami. Melalui grafik, kita bisa melihat bagaimana data tersusun, seberapa besar perbedaannya, dan bagaimana perbandingan antar kelompok. Hal-hal seperti ini sering kali tidak langsung terlihat jika hanya melihat data mentah. Ada beberapa hal yang bisa kita dapat melalui visualisasi:

- Melihat kecenderungan data
- Mengetahui hubungan antar variabel
- Membandingkan antar kelompok

2. Data Understanding from a Visual Perspective.

- a. Describe the dataset used in the Group Project, including **key variables and data types** relevant for visualization.


Dataset yang kelompok kami pakai adalah dataset terkait data employee yang kami ambil dari kaggle. Dalam dataset ini, ada berbagai macam data yang berbeda seperti Education, Joining Year, City, Payment Tier, Age, Gender Ever Benched, Experience in Current Domain, Leave or Not. Berikut adalah penjelasan tiap kolom dalam dataset yang dipilih:

- Education: Berisi tentang tingkat pendidikan karyawan, misal, Bachelor, Master, dan sebagainya.
- Joining Year: Berisi tentang tahun bergabungnya karyawan di company (data dari tahun 2012 - 2018).
- City: Lokasi tempat kerja setiap karyawan.
- Payment Tier: Digunakan untuk mengkategorikan gaji, ada kategori gaji dari 1 sampai 3 yang menjadi pembeda untuk setiap karyawan.
- Age: Umur dari setiap karyawan (range umur di dataset adalah 22-41 tahun).
- Gender: Jenis kelamin karyawan.
- Ever Benched: status karyawan tentang apakah mereka pernah tidak mendapatkan proyek. (isi data cuma Yes/No)
- Experience In Current Domain: Lama pengalaman kerja karyawan di bidang yang sedang dijalani sekarang (total tahun di dataset ada dalam range 1-7 tahun pengalaman).
- Leave or Not: Status karyawan apakah masih bekerja atau sudah keluar. (0= Not leave, 1=Leave)

Dari isi dataset diatas, kita bisa kategorikan menjadi 2 tipe variable, ada categorical variable dan Numeric variable. Berikut beberapa data yang termasuk dalam categorical variable: Education, City, Gender, Payment Tier, Ever Benched, Leave or Not. Data-data berikut biasanya digunakan untuk visualisasi chart seperti bar chart ataupun pie chart. Ada juga tipe numeric variable, contohnya: Age, Joining Year, Experience in Current Domain. Data-data ini cocok untuk histogram, box plot maupun scatter plot.


- b. Identify **visualization-related challenges** in the dataset (e.g., skewed distributions, many categories, overlapping values, extreme values).

Overlapping Values:



Terlihat dari graph Experience vs Leave bahwa distribusi pengalaman kerja antara karyawan yang keluar dan tidak keluar memiliki pola yang hampir sama. Hal ini menunjukkan adanya overlapping, di mana kedua kelompok memiliki rentang nilai yang saling tumpang tindih sehingga sulit dibedakan hanya berdasarkan variabel pengalaman.

Skewed Distribution:



Histogram distribusi usia menunjukkan bahwa data tidak tersebar secara simetris, melainkan cenderung miring ke kanan(right-skewed). Sebagian besar karyawan berada pada usia sekitar 25 hingga 28 tahun, yang terlihat dari frekuensi tertinggi pada interval tersebut. Setelah range usia tersebut, jumlah karyawan mulai berkurang perlahan hingga umur 41. Hal ini menunjukkan bahwa hanya sedikit karyawan yang berada pada kelompok usia lebih tua. Pola distribusi yang tidak merata ini menjadi tantangan dalam visualisasi karena dapat mempengaruhi interpretasi, terutama jika hanya

mengandalkan nilai average, sehingga diperlukan pemahaman lebih lanjut terhadap bentuk distribusi data secara keseluruhan.


- c. Explain how each challenge could **affect visual perception or interpretation** if inappropriate chart types or encodings are used.

Penggunaan visualisasi yang digunakan dengan tidak tepat bisa mengubah persepsi kita memahami data menjadi salah. Misalnya, distribusi yang sebenarnya tidak merata bisa terlihat biasa saja sehingga pola penting jadi terlewat. Data yang saling menumpuk (overlapping) juga bisa membuat banyak nilai terlihat seperti satu, sehingga data di area tertentu tidak terlihat jelas. Selain itu, data yang tidak seimbang bisa membuat satu kategori terlihat lebih menonjol dibanding yang lain. Terlalu banyak kategori juga bisa membuat grafik sulit dibaca, dan adanya nilai ekstrim dapat mengganggu skala sehingga pola utama dalam data jadi kurang terlihat.

3. Exploratory Visualization & Visual Interpretation


- a. Create **at least two exploratory visualizations** to examine the data from different perspectives (e.g., distribution, comparison, relationship).

Comparison example:



Visualisasi ini menunjukkan perbandingan jumlah karyawan pada setiap kategori Payment Tier berdasarkan gender. Grafik ini digunakan untuk melihat apakah terdapat perbedaan distribusi tingkat gaji antara karyawan laki-laki dan perempuan.

Distribution example:



Visualisasi ini menggambarkan distribusi usia karyawan berdasarkan tingkat pendidikan. Boxplot digunakan untuk melihat persebaran data, nilai median, serta mendeteksi adanya nilai ekstrim pada masing-masing kategori pendidikan.

b. Describe the **visual patterns or differences** observed in each visualization.

Pada bar chart, terlihat bahwa jumlah karyawan laki-laki mendominasi pada *Payment Tier 3*, yang merupakan kategori dengan gaji terendah. Sementara itu, pada *Payment Tier 2* dan *1*, distribusi antara laki-laki dan perempuan cenderung lebih seimbang, bahkan pada beberapa kategori jumlah perempuan sedikit lebih tinggi. Pola ini menunjukkan adanya perbedaan distribusi karyawan berdasarkan gender di setiap tingkat gaji.

Pada boxplot, distribusi usia pada masing-masing tingkat pendidikan menunjukkan pola yang relatif serupa. Median usia pada kelompok Bachelors, Masters, dan PHD berada pada rentang yang hampir sama, dengan variasi data yang juga tidak jauh berbeda. Selain itu, terdapat beberapa nilai ekstrim pada setiap kategori, yang menunjukkan adanya karyawan dengan usia yang lebih tinggi dibandingkan mayoritas data. Secara keseluruhan, tidak terlihat perbedaan yang signifikan dalam distribusi usia antar tingkat pendidikan.

c. Explain the **limits of interpretation**, including:

- what the visualizations suggest, and

Visualisasi bar chart menunjukkan adanya perbedaan distribusi karyawan pada setiap payment tier berdasarkan gender, di mana jumlah karyawan laki-laki terlihat lebih dominan pada tier dengan gaji lebih rendah, sementara pada tier yang lebih tinggi distribusinya cenderung lebih seimbang. Selain itu, boxplot memperlihatkan bahwa distribusi usia pada setiap tingkat pendidikan cenderung lebih seimbang, di mana nilai tengahnya berada pada kisaran yang hampir sama serta adanya beberapa data yang berada jauh dari sebagian besar nilai pada masing-masing kategori. Pola-pola ini memberikan gambaran awal mengenai bagaimana karyawan terdistribusi berdasarkan gender, tingkat gaji, usia, dan pendidikan.


- what conclusions **cannot be supported** based on visual evidence alone.
- Belum tentu perbedaan distribusi *Payment Tier* berdasarkan gender berarti bahwa gender menentukan tingkat gaji karyawan.
- Kesamaan pola usia pada setiap tingkat pendidikan tidak berarti bahwa usia dan pendidikan tidak memiliki hubungan.
- Visualisasi hanya menunjukkan pola yang terlihat, sehingga tidak dapat menjelaskan alasan atau penyebab di balik pola tersebut.

4. Early Visualization Design & Justification

- Identify **one focused analytical question** that can be addressed using a single visualization.

Question: Bagaimana distribusi *Payment Tier* berdasarkan Experience in Current Domain untuk semua karyawan?

- Design **one primary visualization** to support this question.



- Justify the design decisions, including:

- chart selection,

Saya memilih menggunakan stacked bar chart karena graph ini bisa menggabungkan dua informasi secara sekaligus yaitu jumlah total karyawan pada setiap tingkat pengalaman kerja serta distribusi *Payment Tier* di dalam setiap kategori tersebut. Jadi, kita tidak hanya melihat perbandingan total employee vs experience in current domain saja, tetapi juga memperlihatkan bagaimana komposisi masing-masing payment tier terbentuk dalam setiap experience in current domain.

- visual encoding choices (position, length, color),

Experience in Current Domain di taruh di x-axis bertujuan supaya bisa menunjukkan urutan kategori secara jelas, jadi, pola perubahan bisa dilihat dari tahun experience terendah hingga terbesar. Y-axis di graph ini berisi total employee, jadi, tinggi bar itu merepresentasikan total employee untuk setiap tahunnya, dan dengan menggunakan bar, kita bisa melihat perbedaan antar bar nya dengan lebih mudah. Warna yang saya pilih masih tergolong kontras meskipun di tumpuk, saya memilih gradasi

transisi warna dari gelap ke terang supaya membantu melihat perbedaan tier lebih mudah, biru muda berarti tier 3(low), biru sedang berarti tier 2(mid), biru gelap berarti tier 1(high).

- and design trade-offs related to clarity and perception.

Stacked bar chart memberikan benefit untuk menyederhanakan informasi yang kompleks menjadi hanya 1 visual graph saja, jadi isi keseluruhan distribusi data dapat lebih mudah untuk dimengerti. Dengan satu graph saja, kita bisa melihat total employee, Experience in current domain dan juga payment tier. Tapi, graph yang saya pilih ini memiliki keterbatasan dalam hal akurasi perbandingan antar kategori, karena ada bagian yang saling menumpuk, jadi kita tidak bisa membandingkannya dengan akurat karena tiap tier tidak memiliki baseline yang sama. Akibatnya, perbandingan untuk setiap payment tier menjadi kurang presisi, terutama untuk part yang tidak di bagian dasar dari graph.

Link Google Collab: [uts_datavis.ipynb](https://colab.research.google.com/github/uts-datavis/uts-datavis/blob/main/uts-datavis.ipynb)